

ชื่อโครงการ (ภาษาไทย) :

ระบบตรวจจับการใส่หมวกเซฟตี้เพื่อเพิ่มความปลอดภัยในพื้นที่เสี่ยง ด้วยเทคโนโลยี AI

Project Title (English) :

Safety Helmet Detection System for High-Risk Areas Using AI Technology

บทคัดย่อ —

การวิจัยครั้งนี้ มีวัตถุประสงค์เพื่อพัฒนาระบบตรวจจับการใส่หมวกเซฟตี้ แยกแยะสีของหมวกเซฟตี้ รวมทั้งตรวจจับผู้ที่ไม่ใส่หมวกเซฟตี้จากภาพ ด้วยเทคโนโลยีปัญญาประดิษฐ์ (AI), คอมพิวเตอร์วิทัศน์ (Computer Vision), การเรียนรู้เชิงลึก (Deep Learning) การตรวจจับวัตถุ (Object Detection), การประมวลผลภาพ (Image Processing) โดยใช้โมเดล SSD (Single Shot MultiBox Detector) เก็บข้อมูลพนักงานที่ทำงานในแต่ละพื้นที่ นำมาวิเคราะห์เวลาทำงาน จำนวนพนักงาน ในการตรวจสอบและพัฒนาประสิทธิภาพการทำงาน ผลลัพธ์ของการทดลอง ระบบสามารถตรวจจับด้วยความแม่นยำสูงสุด 90.50% ซึ่งมีศักยภาพในการนำไปประยุกต์ใช้งานในภาคอุตสาหกรรมอย่างมีประสิทธิภาพ

คำสำคัญ — ปัญญาประดิษฐ์, คอมพิวเตอร์วิทัศน์, การตรวจจับวัตถุ, การเรียนรู้เชิงลึก, การตรวจจับการใส่หมวกเซฟตี้

I. บทนำ

ความปลอดภัยในสถานที่ทำงาน โดยเฉพาะในอุตสาหกรรมก่อสร้าง โรงงานผลิต และพื้นที่ปฏิบัติงานที่มีความเสี่ยงสูง เป็นหัวใจสำคัญในการป้องกันอุบัติเหตุที่อาจส่งผลกระทบต่อชีวิตพนักงาน และประสิทธิภาพขององค์กร พื้นที่ทำงานเหล่านี้มักมีปัจจัยเสี่ยงที่อาจก่อให้เกิดอุบัติเหตุรุนแรงได้ เช่น การทำงานบนที่สูง ซึ่งอาจนำไปสู่การพลัดตก การใช้เครื่องจักรกลหนัก ที่อาจก่อให้เกิดการชนหรือกระแทก และ การสัมผัสวัตถุอันตราย ที่อาจส่งผลกระทบต่อสุขภาพและความปลอดภัยของพนักงาน การเกิดอุบัติเหตุในสถานที่ทำงานไม่ได้ส่งผลกระทบต่อผู้ที่ได้รับบาดเจ็บเท่านั้น แต่ยังส่งผลกระทบต่อองค์กรในหลายมิติ เช่น ความสูญเสียทางเศรษฐกิจ เนื่องจากค่าใช้จ่ายในการรักษาพยาบาลและค่าชดเชยพนักงาน การหยุดชะงักของกระบวนการผลิต และ ผลกระทบด้านชื่อเสียงขององค์กร ที่อาจทำให้สูญเสียความไว้วางใจจากลูกค้าและพาร์ทเนอร์ทางธุรกิจ ด้วยเหตุนี้ บริษัทและสถานประกอบการจึงต้องมีมาตรการป้องกันที่เข้มงวดเพื่อลดความเสี่ยงที่อาจเกิดขึ้น

หนึ่งในมาตรการพื้นฐานที่สำคัญคือ การสวมใส่อุปกรณ์ป้องกันส่วนบุคคล (Personal Protective Equipment: PPE) ซึ่งรวมถึงเสื้อผ้าสะท้อนแสง ถุงมือป้องกัน รองเท้านิรภัย และที่สำคัญคือ หมวกเซฟตี้ (Safety Helmet) หมวกเซฟตี้มีบทบาทสำคัญในการลดความรุนแรงของอุบัติเหตุที่เกี่ยวข้องกับศีรษะ เช่น วัตถุตกจากที่สูง หรือการกระแทกจากเครื่องจักร อย่างไรก็ตาม แม้ว่าหมวกเซฟตี้จะเป็นมาตรการป้องกันที่มีประสิทธิภาพ แต่ในหลายกรณีกลับพบว่า พนักงานบางส่วนไม่ได้ปฏิบัติตามข้อกำหนดในการสวมใส่ หรืออาจสวมใส่ไม่ถูกต้อง ส่งผลให้เกิดความเสี่ยงต่อการบาดเจ็บที่อาจร้ายแรงถึงชีวิต

ศีรษะเป็นส่วนที่บอบบางและอ่อนไหวต่อการบาดเจ็บ การได้รับแรงกระแทกบริเวณศีรษะอาจส่งผลให้เกิดการบาดเจ็บรุนแรง เช่น กะโหลกร้าว สมองกระทบกระเทือน หรือในบางกรณีอาจนำไปสู่ความพิการหรือเสียชีวิต หมวกเซฟตี้ถูกออกแบบมาเพื่อลดแรงกระแทกและกระจายแรงกระทำที่อาจเกิดขึ้นเมื่อมีวัตถุตกลงมากระแทก

บริเวณศีรษะ โดยวัสดุที่ใช้ทำหมวกเซฟต์มักเป็น พลาสติกแข็งที่ทนต่อแรงกระแทกสูง (High-Density Polyethylene หรือ HDPE) และมีโฟมรองรับแรงกระแทกเพื่อลดความรุนแรงที่ส่งไปถึงศีรษะ นอกจากนี้ สีของหมวกเซฟต์ยังมีความหมายและความสำคัญในสถานที่ทำงาน โดยปกติแล้ว สีของหมวกเซฟต์จะถูกใช้เพื่อแยกแยะประเภทของพนักงานและบทบาทหน้าที่ เช่น

- หมวกสีขาว สำหรับวิศวกร ผู้ควบคุมงาน และเจ้าหน้าที่ระดับผู้บริหาร
- หมวกสีเหลือง สำหรับแรงงานทั่วไป
- หมวกสีฟ้า สำหรับช่างเทคนิคและพนักงานซ่อมบำรุง
- หมวกสีแดง สำหรับเจ้าหน้าที่ดับเพลิงหรือพนักงานที่ปฏิบัติงานเกี่ยวกับความปลอดภัย
- หมวกสีเขียว สำหรับเจ้าหน้าที่สิ่งแวดล้อมหรือความปลอดภัย
- หมวกสีส้ม หรือ สีมะม่วง สำหรับผู้มาเยี่ยมชมสถานที่

การแยกประเภทของพนักงานด้วยสีของหมวกเซฟต์ช่วยให้เจ้าหน้าที่สามารถระบุหน้าที่ของบุคลากรในพื้นที่ปฏิบัติงานได้ง่ายขึ้น รวมถึงสามารถตรวจสอบได้ว่ามีบุคคลที่ไม่ได้รับอนุญาตเข้าพื้นที่หรือไม่

ในสถานที่ทำงานขนาดใหญ่ เช่น โรงงานอุตสาหกรรม ไซต์ก่อสร้าง หรือคลังสินค้า การตรวจสอบการปฏิบัติตามมาตรการด้านความปลอดภัยมักใช้การสังเกตโดยเจ้าหน้าที่ตรวจสอบหรือหัวหน้างาน ซึ่งเป็นกระบวนการที่ต้องใช้แรงงานคนเป็นจำนวนมากและอาจมีข้อผิดพลาดเกิดขึ้น นอกจากนี้ ในบางสถานการณ์ เช่น กะการทำงานที่มีจำนวนพนักงานหมุนเวียนสูง หรือพื้นที่ที่มีกล้องวงจรปิดเฝ้าระวังอยู่แล้ว การใช้เทคโนโลยีเข้ามาช่วยในการตรวจจับการสวมใส่หมวกเซฟต์จึงเป็นแนวทางที่สามารถช่วยลดภาระของเจ้าหน้าที่ เพิ่มความแม่นยำในการตรวจสอบ และช่วยให้เกิดการบังคับใช้กฎระเบียบได้อย่างมีประสิทธิภาพมากขึ้น

ด้วยเหตุนี้ งานวิจัยนี้จึงมุ่งเน้นไปที่การพัฒนา ระบบตรวจจับการใส่หมวกเซฟต์โดยใช้เทคโนโลยีปัญญาประดิษฐ์ (AI) และคอมพิวเตอร์วิทัศน์ (Computer Vision) ซึ่งสามารถทำงานได้แบบอัตโนมัติ เพื่อลดข้อผิดพลาดที่อาจเกิดขึ้นจากการตรวจสอบแบบเดิม และช่วยให้สถานประกอบการสามารถเพิ่มมาตรฐานด้านความปลอดภัยได้อย่างมีประสิทธิภาพ

II. ทฤษฎีที่เกี่ยวข้อง

ในงานวิจัยนี้ ได้นำเอาหลักการและทฤษฎีจากหลายสาขามาประกอบกัน เพื่อพัฒนาระบบตรวจจับการสวมหมวกเซฟต์ให้มีความแม่นยำและตอบสนองได้อย่างรวดเร็ว ซึ่งแนวคิดเหล่านี้ประกอบด้วย การประยุกต์ใช้เทคโนโลยีปัญญาประดิษฐ์ (AI), คอมพิวเตอร์วิทัศน์ (Computer Vision), การเรียนรู้เชิงลึก (Deep Learning) การตรวจจับวัตถุ (Object Detection), การประมวลผลภาพ (Image Processing)

///.i) ปัญญาประดิษฐ์ (AI) เป็นรากฐานสำคัญที่ทำให้คอมพิวเตอร์สามารถเรียนรู้และตัดสินใจได้ด้วยตนเอง ช่วยให้ระบบสามารถวิเคราะห์และประมวลผลข้อมูลภาพที่ได้รับจากกล้องวงจรปิดได้อย่างอัตโนมัติ ทำให้สามารถจำแนกและคัดแยกบุคคลที่สวมหรือไม่สวมหมวกเซฟตี้ได้อย่างแม่นยำ

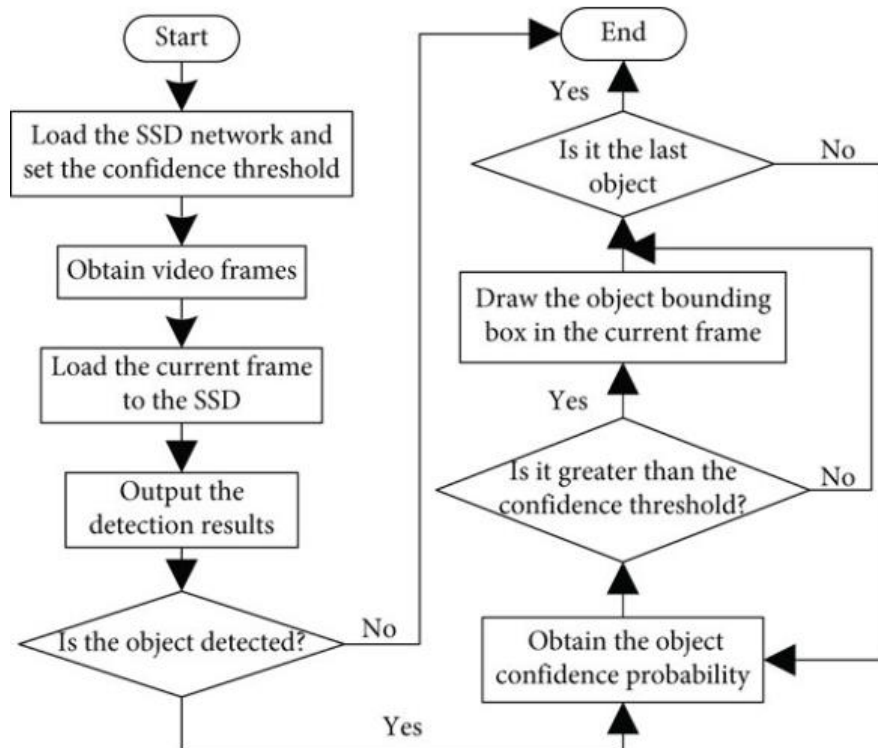


Figure 1: โครงสร้างระบบ AI สำหรับตรวจจับวัตถุ

///.ii) คอมพิวเตอร์วิทัศน์ (Computer Vision) คือการที่คอมพิวเตอร์สามารถ “มองเห็น” วิเคราะห์และตีความข้อมูลจากภาพหรือวิดีโอได้ ซึ่งในงานนี้จะใช้เทคนิคการจับภาพเพื่อแยกแยะลักษณะเฉพาะของบุคคลในสภาพแวดล้อมที่มีความซับซ้อน เช่น การเปลี่ยนแปลงของแสงและมุมมองที่แตกต่างกัน ข้อมูลภาพที่ได้จะถูกนำไปผ่านกระบวนการประมวลผล เพื่อสร้างคุณลักษณะที่สำคัญ (features) สำหรับการจำแนกวัตถุ




Figure 2: การตรวจจับวัตถุด้วยกล้อง CCTV

III.iii) การเรียนรู้เชิงลึก (Deep Learning) หนึ่งในสาขาของ Machine Learning ซึ่งใช้ในการสอนปัญญาประดิษฐ์ ถูกออกแบบมาเพื่อจำลองการทำงานของสมองของมนุษย์ในการรับข้อมูลและเรียนรู้ผ่านประสบการณ์ โดยจุดเด่นของ Deep Learning คือการประมวลผลข้อมูลที่ไม่โครงสร้างหรือ Unstructured Data ข้อแตกต่างของ Deep Learning และ Machine Learning คือ Deep Learning จะมีจำนวน Hidden Layer มากกว่า และสามารถกำหนดจำนวน Layer และ Node ได้อย่างอิสระ Deep Learning โดยเฉพาะการใช้โครงข่ายประสาทเทียมแบบ Convolutional Neural Networks (CNN) ได้รับความนิยมอย่างสูงในการวิเคราะห์ภาพ เนื่องจากสามารถดึงคุณลักษณะที่สำคัญจากข้อมูลภาพได้โดยอัตโนมัติ งานวิจัยนี้เลือกใช้โมเดล SSD (Single Shot MultiBox Detector)




Figure 3: โครงสร้างของ Deep Learning

- i) SSD (Single Shot MultiBox Detector) ซึ่งเป็นโมเดลตรวจจับวัตถุที่สามารถคาดการณ์ตำแหน่งและจำแนกประเภทของวัตถุได้ในขั้นตอนเดียวสามารถประมวลผลข้อมูลแบบเรียลไทม์และมีความแม่นยำสูง ประกอบด้วยโครงสร้างฐาน (ซึ่งในกรณีนี้คือ MobileNet) ตามด้วยเลเยอร์คอนโวลูชันหลายชั้น

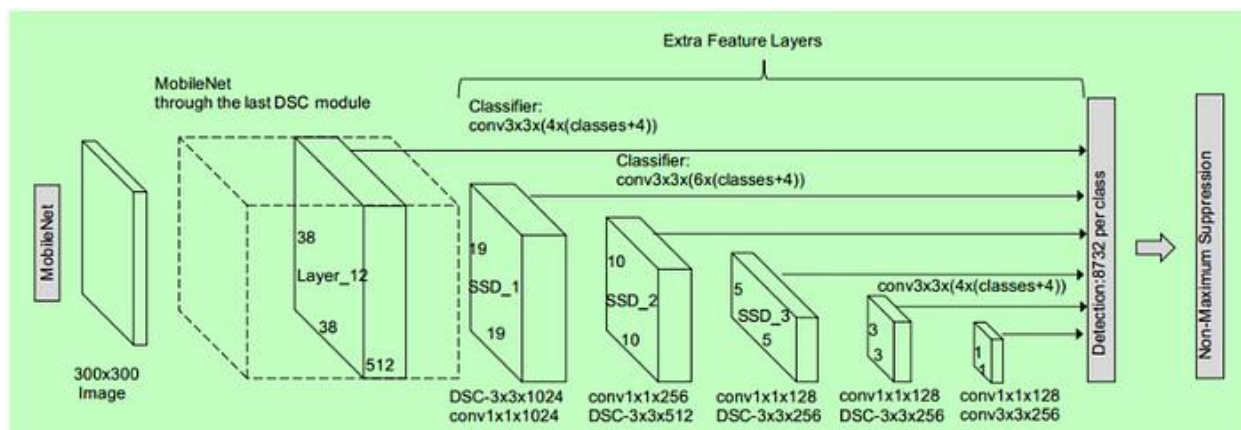


Figure 4: โครงสร้างของโมเดล SSD ที่มีฐานเป็น MobileNet

III.iv) การประมวลผลภาพและการเตรียมข้อมูล (Image Processing and Data Pre-processing)

ซึ่งเป็นขั้นตอนที่ช่วยปรับปรุงคุณภาพของภาพก่อนนำไปฝึกสอนโมเดล ภาพจากกล้องวงจรปิดอาจมีสัญญาณรบกวน (noise) หรือมีขนาดและความสว่างที่ไม่เท่ากัน การปรับขนาด (resizing) การทำ augmentation เพื่อลากขยายข้อมูล และการลด noise ช่วยให้ข้อมูลที่ส่งเข้าโมเดลมีความสอดคล้องและมีคุณภาพสูงขึ้น

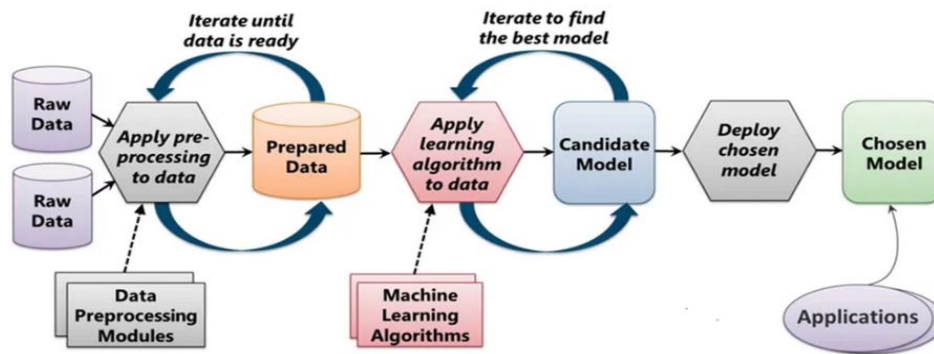


Figure 5: กระบวนการ Pre-processing ของภาพ

โดยสรุปแล้ว ทฤษฎีและแนวคิดที่เกี่ยวข้องในงานวิจัยนี้เป็นการบูรณาการเทคโนโลยีจากหลากหลายสาขาเข้าด้วยกัน เพื่อสร้างระบบตรวจจับการสวมหมวกเซฟตี้ที่สามารถทำงานได้อย่างมีประสิทธิภาพในสภาพแวดล้อมจริง การบูรณาการความเทคโนโลยี AI, Computer Vision, Deep Learning, Object Detection และ Image Processing ทำให้ระบบมีความสามารถในการตรวจจับและตอบสนองต่อเหตุการณ์ผิดปกติได้อย่างทันที และสามารถวิเคราะห์ข้อมูลการทำงานของพนักงานทีในแต่ละพื้นที่ได้

III. ระบบที่นำเสนอ

ระบบตรวจจับการใส่หมวกเซฟตี้เพื่อเพิ่มความปลอดภัยในพื้นที่เสี่ยง ด้วยเทคโนโลยี AI

แนวคิดของระบบ

ระบบที่ใช้ Deep Learning และ Computer Vision แยกแยะและตรวจจับการใส่หมวกเซฟตี้ในพื้นที่ต่างๆ เช่น พื้นที่ก่อสร้าง พื้นที่อันตราย หรือพื้นที่ที่จำเป็นต้องใช้หมวกเซฟตี้

IV. การเตรียมชุดข้อมูล

ประกอบด้วย ชุดข้อมูลจาก Roboflow และอินเทอร์เน็ต โดยจำนวน dataset มีจำนวน 1968 รูป และเข้าสู่กระบวนการ Annotate เพื่อแบ่งคลาสให้กับ dataset ที่มี ได้แก่

- ผู้ที่ไม่ใส่หมวกเซฟตี้ จำนวน 383 รูป
- หมวกเซฟตี้สีแดง จำนวน 356 รูป
- หมวกเซฟตี้สีเหลือง จำนวน 754 รูป
- หมวกเซฟตี้สีน้ำเงิน จำนวน 652 รูป
- หมวกเซฟตี้สีขาว จำนวน 840 รูป

COLOR	CLASS NAME	COUNT ↻
	blue helmet	652
	head	383
	red helmet	356
	white helmet	840
	yellow helmet	754

Figure 6: Dataset และ Class ของDataset

และได้มีการปรับขนาดของรูปภาพก่อนการฝึกสอน โดยแปลงภาพให้เหมาะสม เป็น 640x640 พิกเซล

IV.i) องค์ประกอบของระบบ

โมดูลตรวจจับหมวกเซฟตี้(Safety Helmet Detection Module)

โมเดล YOLO ซึ่งเป็นโมเดลตรวจจับวัตถุที่สามารถคาดการณ์ตำแหน่ง และจำแนกประเภทของวัตถุได้ในขั้นตอนเดียว ทำให้สามารถประมวลผลข้อมูลแบบเรียลไทม์และมีความแม่นยำสูง

กระบวนการทำงาน :

- รับภาพจากกล้อง CCTV หรือ ไฟล์ภาพ
- ใช้โมเดล AI สำหรับการตรวจจับ ในการตรวจจับการใส่หมวกเซฟตี้
- แสดงผล Bounding Box และจำแนกสีของหมวก กับผู้ไม่ใส่หมวก
- บันทึกข้อมูลที่ตรวจจับ

ตัวอย่างการใช้งานจริง : ระบบตรวจจับความปลอดภัยในพื้นที่เสี่ยง หรือพื้นที่ก่อสร้าง

เทคโนโลยีที่ใช้ :

- ภาษา: Python
- ไลบรารี: OpenCV, TensorFlow/PyTorch, Ultralytic, Scikit-learn
- ฮาร์ดแวร์ที่รองรับ: กล้อง CCTV, Raspberry Pi ,GPU-based Server
- โมเดล:YoLoV8n, NODE_RED,SSD

โมเดลการเรียนรู้เชิงลึก : มีหลายตัวเลือก ขึ้นอยู่กับความซับซ้อนและความต้องการของโปรเจค โดยทั่วไปสามารถแบ่งเป็นสองส่วนหลัก :

1. การตรวจจับวัตถุ (Object Detection)
 - YOLO (You Only Look Once) – เหมาะสำหรับงานที่ต้องการความเร็วและ ความแม่นยำ
 - SSD (Single Shot Multibox Detector) – สมดุลระหว่างความเร็วและความแม่นยำ
2. การจำแนกสี (Color Classification)

- ใช้ CNN (Convolutional Neural Network) เช่น ResNet, MobileNet หรือใช้โมเดลที่เบากว่า เช่น SqueezeNet
- ใช้เทคนิค Color Histogram + Machine Learning เช่น SVM หรือ Random Forest
- ใช้ Deep Learning + Transfer Learning จากโมเดลที่ถูกฝึกสอนมาแล้ว เช่น VGG16, EfficientNet

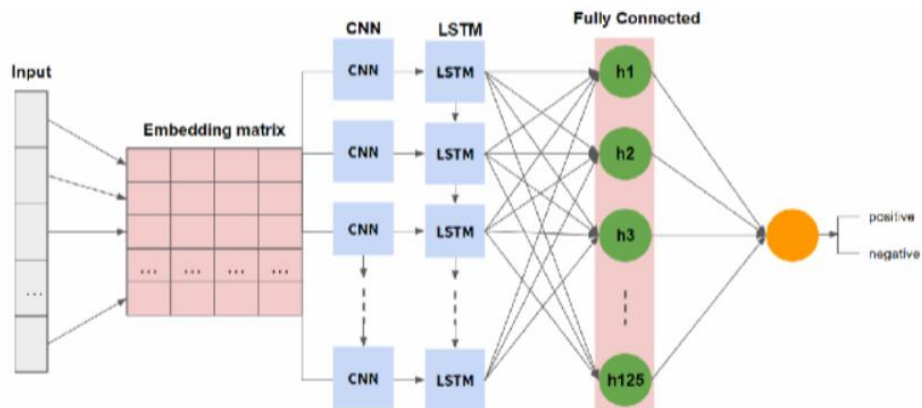


Figure 7 : โครงสร้างของโมเดลการเรียนรู้เชิงลึกแบบผสมผสานที่น่าเสนอ
ผลลัพธ์จากการทดลอง

Ex p. No.	Model	Epoch	Batch Size	Learning rate	mAP	Accuracy (%)	Recall	
1	ssd mobilenet	20	8	0.008	72.16	87.00	87.00	Accuracy: 87.00% Precision: 95.44% Recall: 87.00% F1 Score: 90.75% mAP: 72.16%
2	ssd mobilenet	20	16	0.008	70.40	91.00	91.00	Accuracy: 91.00% Precision: 92.77% Recall: 91.00% F1 Score: 91.60% mAP: 70.40%
3	ssd mobilenet	100	16	0.008	58.43	83.00	83.00	Accuracy: 83.00% Precision: 95.55% Recall: 83.00% F1 Score: 88.14% mAP: 58.34%
4	ssd mobilenet	120	16	0.008	63.40	90.50	90.50	2025-02-27 23:27:16.3764 Accuracy: 90.50% Precision: 97.96% Recall: 90.50% F1 Score: 93.38% mAP: 63.40%

Figure 8 : ตารางการฝึกสอนของ Model SSD MobileNet


```
(D:\AnacondaEnv\tf_env) D:\adn_cctv\models\research>python evaluate.py
2025-03-03 04:10:00.085026: I tensorflow/core/platform/cpu_feature_guard.cc:151] This TensorFlow binary is optimized with
oneAPI Deep Neural Network Library (oneDNN) to use the following CPU instructions in performance-critical operations:
AVX AVX2
To enable them in other operations, rebuild TensorFlow with the appropriate compiler flags.
2025-03-03 04:10:00.165269: I tensorflow/core/common_runtime/gpu/gpu_device.cc:1525] Created device /job:localhost/replica:0/task:0/device:GPU:0 with 2242 MB memory: -> device: 0, name: NVIDIA GeForce GTX 1650 Ti, pci bus id: 0000:01:00.0,
compute capability: 7.5
2025-03-03 04:10:09.741200: I tensorflow/stream_executor/cuda/cuda_dnn.cc:368] Loaded cuDNN version 8100
Accuracy: 90.50%
Precision: 97.96%
Recall: 90.50%
F1 Score: 93.38%
mAP: 63.40%
✓ true_labels: [3 3 3 4 5]
✓ predicted_labels: [3 3 0 4 5]
✓ บันทึกค่า y_true และ y_pred ลงไฟล์ ssd_results.json แล้ว!
```

Figure 9 : ผลลัพธ์จากการฝึกสอนของ Model SSD MobileNet

จากการทดลองครั้งที่ 1 และ 2 เมื่อทดสอบแล้ว พบว่า bounding box ซ้อนทับกัน และผลลัพธ์ไม่ถูกต้อง




Figure 10 : ผลลัพธ์จากการทดสอบโมเดลครั้งที่ 1 และ 2

ต่อมาได้ทำการฝึกสอนโมเดลโดยเพิ่ม num_step = 10,000 , batch_size = 16 และ threshold = 0.65



Figure 11 : ผลลัพธ์จากการทดสอบโมเดลครั้งที่ 3

พบว่าโมเดลมีความแม่นยำ ถูกต้องมากขึ้น แต่ค่าความแม่นยำยังไม่เป็นที่พึงพอใจมากนักจึงทำการฝึกสอนอีกครั้ง โดยเพิ่ม num_step = 12,000 และ Non-Maximum Suppression = 0.04



Figure 12 : ผลลัพธ์จากการทดสอบโมเดลครั้งที่ 4

จากผลการทดลองทั้ง 4 ครั้ง สังเกตได้ว่า เมื่อทำการฝึกสอนโดยเพิ่ม epoch แต่ความแม่นยำที่ได้กลับน้อยลง คาดว่าเกิดจากการ Overfitting ของข้อมูล

Overfitting เป็นปัญหาที่เกิดขึ้นเมื่อ Machine Learning ทำงานได้ดี มีความแม่นยำสูง ทำนายแม่นยำกับ training data แต่ทำงานได้แย่ ไม่แม่นยำ เมื่อเจอข้อมูลใหม่ ๆ หรือ ข้อมูลที่ไม่เคยเห็นมาก่อน (testing data)




Figure 13 : ภาพอธิบายการ Overfitting

สาเหตุของ Overfitting

1. ข้อมูลฝึกสอนน้อย: ข้อมูลฝึกสอนจำนวนน้อยมากเทียบกับความซับซ้อนของโมเดล โมเดลอาจจะมีโอกาส Overfit ได้สูง เพราะมันจะพยายามจดจำข้อมูลฝึกสอนแทบทุกอย่าง
2. ความซับซ้อนของโมเดล: โมเดลที่มีโครงสร้างซับซ้อนมาก มีจำนวนพารามิเตอร์มาก มีโอกาสที่จะ Overfit ได้สูง เพราะใช้พารามิเตอร์มากมายในการเรียนรู้ข้อมูลฝึกสอน
3. การฝึกสอนนานเกินไป: การฝึกสอนโมเดลเรียนรู้เชิงลึกนานเกินไปอาจทำให้โมเดลจดจำข้อมูลฝึกสอนได้อย่างละเอียดเกินไป และทำให้ Overfit ได้

และเนื่องจากโมเดลมีอัตราส่วนระหว่างข้อมูลที่ใช้ฝึกสอนกับจำนวน batch_size ที่อาจไม่สอดคล้องกันทำให้เกิดการ Overfitting ได้ สามารถแก้ไขได้ ดังนี้

วิธีแก้ไข

1. เพิ่มข้อมูลฝึกสอน: ทำให้โมเดลมีโอกาสรู้และทำนายข้อมูลที่หลากหลายมากขึ้น
2. ลดความซับซ้อนของโมเดล: ลดจำนวนพารามิเตอร์หรือความซับซ้อนของโมเดล เช่น ใช้โมเดลที่มีความลึกน้อยลงหรือใช้เทคนิค Regularization เพื่อลดการเรียนรู้ที่เกินไป

3. ใช้ Cross-Validation: Cross-validation เป็นเทคนิคที่ช่วยวัดประสิทธิภาพของโมเดลอย่างถูกต้อง และช่วยในการเลือกพารามิเตอร์ที่เหมาะสม
4. เลือกข้อมูลที่มีคุณค่า: การเลือกข้อมูลที่มีคุณค่าและเกี่ยวข้องกับปัญหาที่เราต้องการทำนายช่วยลดโอกาสในการ Overfitting

ทั้งนี้ควรแก้ไขให้พอดีเพื่อไม่ให้เกิด Overfitting หรือ Underfitting




Figure 14 : Confusion Matrix Table ของไฟล์ evaluate.py

V. สรุป

งานวิจัยนี้ตระหนักเห็นถึงความจำเป็นอย่างยิ่งที่จะต้องพัฒนางานวิจัยในการตรวจจับและจำแนกสีของหมวกเซฟตี้ เพื่อเพิ่มประสิทธิภาพในการจัดการความปลอดภัยในพื้นที่ต่างๆ โดยนำเทคโนโลยี Deep Learning และ Machine Learning ร่วมกับการวิเคราะห์ข้อมูลสีเพื่อเพิ่มประสิทธิภาพในการจำแนกประเภท ระบบนี้สามารถนำไปประยุกต์ใช้งานได้หลากหลาย เช่น การรักษาความปลอดภัยในพื้นที่สาธารณะ การควบคุมการเข้าถึงเฉพาะจุด การวิเคราะห์ข้อมูลการทำงานของพนักงาน และการตรวจจับพฤติกรรมผิดปกติผ่านกล้องวงจรปิด เทคโนโลยีหลักที่นำมาใช้รวมถึงภาษา Python, OpenCV, TensorFlow/PyTorch, YOLO, Faster R-CNN พร้อมกับการวิเคราะห์ Histogram ของสี ซึ่งช่วยให้ระบบมีความสามารถในการแยกแยะสีหมวกได้อย่างแม่นยำและตอบสนองต่อเหตุการณ์ได้อย่างรวดเร็ว

เอกสารอ้างอิง

GeeksforGeeks. (n.d.). Introduction to deep learning. Retrieved March 3, 2025, from <https://www.geeksforgeeks.org/introduction-deep-learning/>

Roboflow. (n.d.). MobileNet SSD v2 model. Retrieved March 3, 2025, from <https://roboflow.com/model/mobilenet-ssd-v2>

Viso.ai. (n.d.). Object detection: Guide to deep learning models & applications. Retrieved March 3, 2025, from <https://viso.ai/deep-learning/object-detection/>

Techmayank2000. (2023, July 10). Object detection using SSD MobileNetV2 using TensorFlow API: Can detect any single class. Medium. Retrieved March 3, 2025, from <https://medium.com/@techmayank2000/object-detection-using-ssd-mobilenetv2-using-tensorflow-api-can-detect-any-single-class-from-31a31bbd0691>

Disrupt Ignite. (n.d.). Deep learning. Retrieved March 3, 2025, from <https://www.disruptignite.com/blog/deep-learning>

Everyday Marketing. (n.d.). Overfitting vs. underfitting: Word about problems arising from the complexity of data. Retrieved March 3, 2025, from <https://everydaymarketing.co/knowledge/overfitting-vs-underfitting-word-about-problems-arising-from-the-complexity-of-data/>

[1] R. Masque, "Accuracy decreasing with higher epochs," Stack Overflow, Nov. 11, 2018. Available: <https://stackoverflow.com/questions/53242875/accuracy-decreasing-with-higher-epochs>. Accessed: Mar. 3, 2025.

GeeksforGeeks. (n.d.). Underfitting and overfitting in machine learning. Retrieved March 3, 2025, from <https://www.geeksforgeeks.org/underfitting-and-overfitting-in-machine-learning/>